Vai filma saņems augstu vērtējumu?

Mašīnmācīšanās modeļa izstrāde filmu panākumu prognozēšanai

Filmu klasificēšana pēc to potenciālā vērtējuma, izmantojot *Logistic Regression* modeli, sasniedzot F1 rezultātu 0.70

Dace Pinka, 2026.gada aprīlis

Problēmas definīcija un datu kopa

Mērķis: Identificēt galvenos faktorus, kas nosaka filmas augstu vērtējumu (*vote_average*).

Filmas vērtējuma prognozēšana ir būtiska straumēšanas pakalpojumiem un filmu producentiem, lai saprastu, kādi faktori korelē ar skatītāju apmierinātību.

Datu avots: Kaggle (TMDb Top 10,000 Popular Movies Dataset).

Apjoms: Pēc tīrīšanas 9804 rindas un 6 svarīgākās pazīmes.

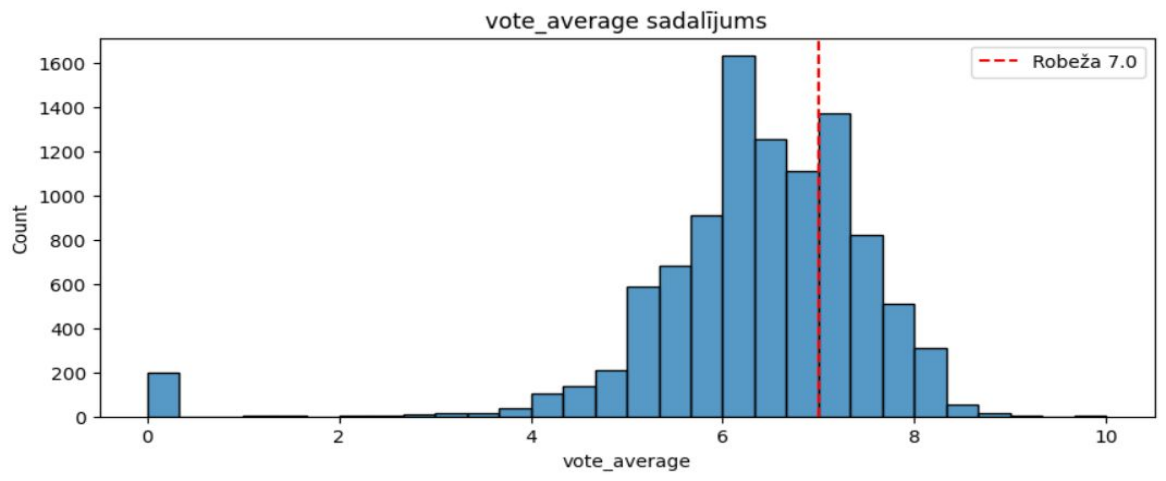

Metodoloģija un datu inženierija

Mērķa definīcija: Binārā klasifikācija (1 = vērtējums > 6.5; 0 = zemāks).

Feature Engineering:

- gada (*year*) izdalīšana no datuma.
- valodas binārais kodējums (*lang_en*).

Pipeline

Trūkstošo vērtību aizpildīšana (*SimpleImputer*) → Mērogošana (*StandartScaler*) → Modelis (*LogicRegression*)

Modeļa optimizācija

Bāzes modelis: F1 score = 0.4392 (bez hiperparametru regulēšanas).

Uzlabotais modelis: Izmantots *GridSearchCV* optimālajiem parametriem.

Rezultāts: F1 score = 0.6042 (+37.6% pieaugums).

Pagrieziena punkts: augsta/zema vērtējuma sliekšņa maiņa no 7.0 uz 6.5 būtiski uzlaboja modeļa spēju atpazīt "labās" filmas.

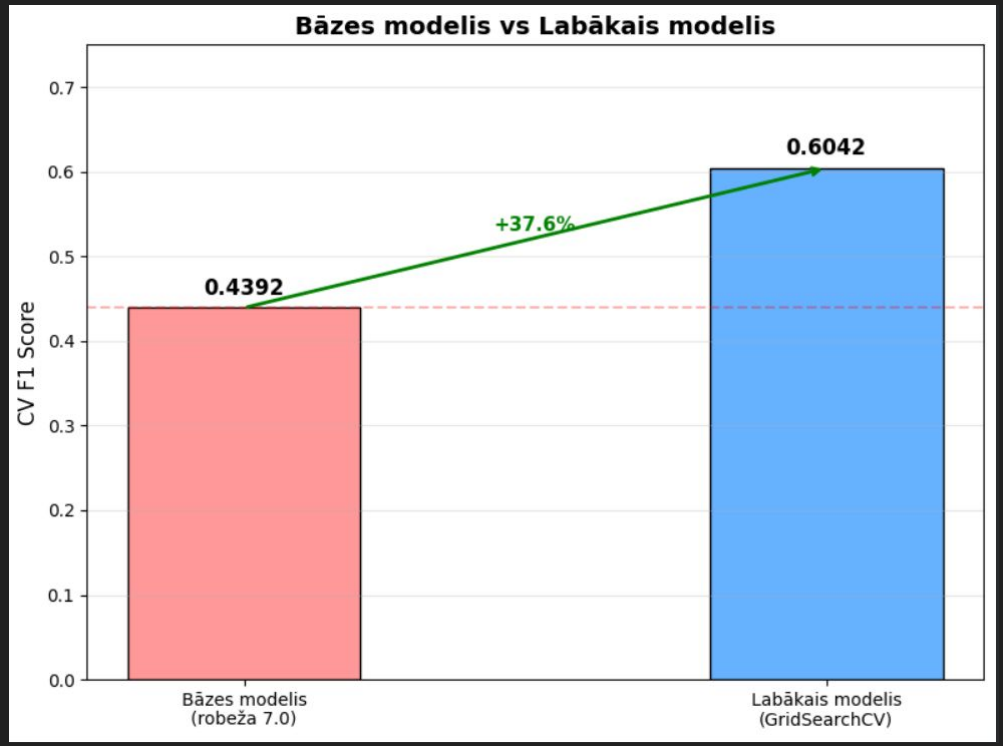

Modeļa veiktspējas analīze

Metrikas: Accuracy = 71%, F1 = 0.70

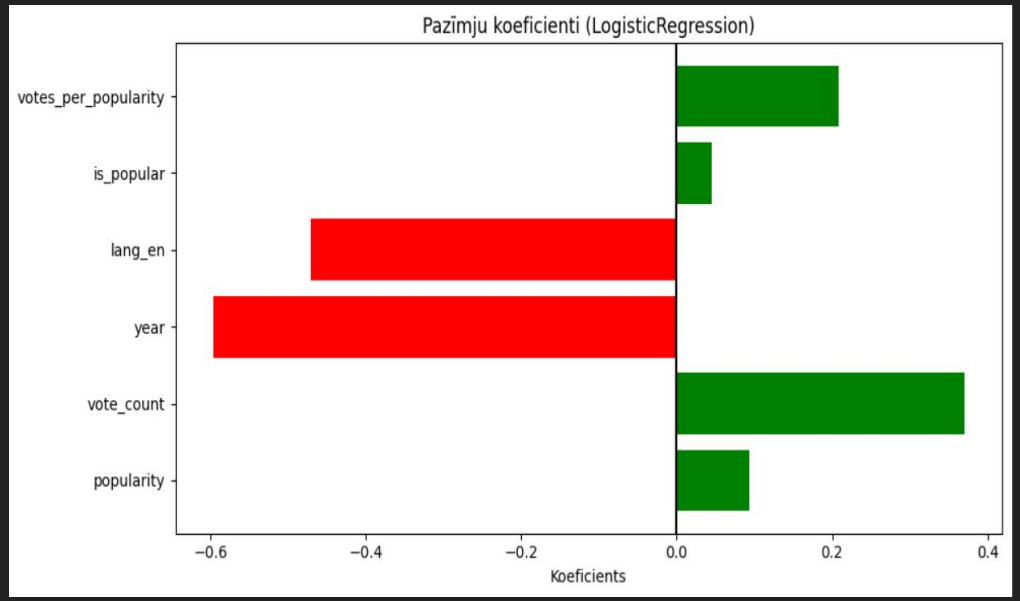

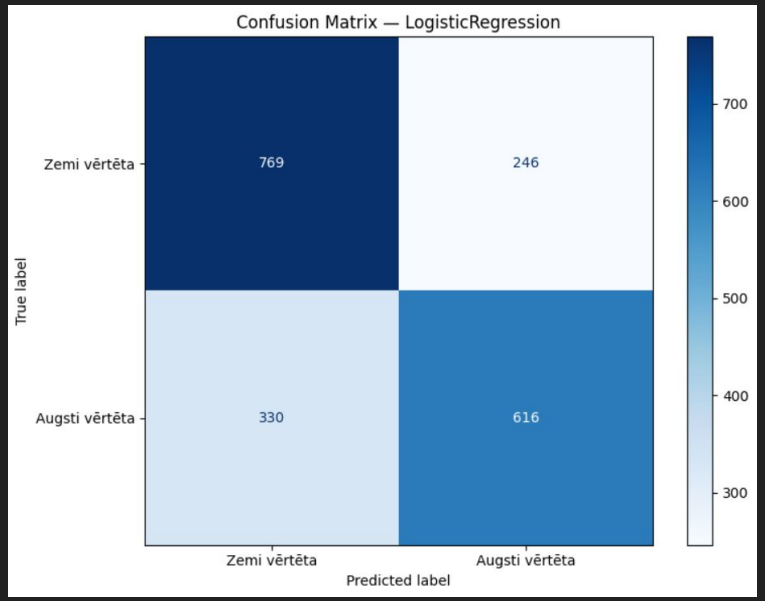

Secinājumi

Atziņa: Vecākas filmas un filmas, kas nav angļu valodā, statistiski saņem augstākus vērtējumus šajā datu kopā.

Ierobežojumi: Modelis joprojām kļūdās 35% gadījumu pie augstiem vērtējumiem (nepieciešami papildu dati, papildu iezīmes).

Nākamie soļi:

- iekļaut žanru informāciju (Action, Drama, utt.) kā papildu iezīmi;
- izmēģināt vairāku modeļu (*Random Forest* vai *XGBoost)* ensemble metodes.

Paldies!